

Mociño Navarrete Naomi Yotana

① Tokenización simple:

1. Hola!
2. estoy
3. aprendiendo
4. NLP
5. :)
6. CTU
7. también?

④ En NLP, los emojis y signos de puntuación pueden ser informativos, no solo por ruido. Por ejemplo, :), !, ¿? ayudan a detectar emoción, tono, ironía, sarcasmo o intención.

② Eliminación de signos

1. Hola
2. estoy
3. aprendiendo
4. NLP
5. TU
6. también

③ Convertir a minúsculas

1. hola
2. estoy
3. aprendiendo
4. nlp
5. también
6. tu

Problema 2.

① Vocabulario

- me
- gusta
- la
- inteligencia
- artificial
- es
- fascinante

Matriz Bow

[me, gusta, la, inteligencia, artificial, es, fascinante]

Documento	me	gusta	la	inteligencia	artificial	es	fascinante
"me gusta la inteligencia artificial"	1	1	1	1	1	0	0
"la inteligencia artificial es fascinante"	0	0	1	1	1	1	1

La Bow pierde el orden de las palabras, así que no sabe como se relacionan las palabras en la oración perdiendo contexto, negación y significado composicional.

Problema 3

$TF(t, d) = \frac{\text{número de veces que aparece el término en el documento}}{\text{total de palabras del documento}}$

Doc 1: palabra	TF	TF
me	$1/5 = 0.2$	$0/5 = 0$
gusta	$1/5 = 0.2$	$0/5 = 0$
la	$1/5 = 0.2$	$1/5 = 0.2$
inteligencia	$1/5 = 0.2$	$1/5 = 0.2$
artificial	$1/5 = 0.2$	$1/5 = 0.2$
es	$0/5 = 0$	$1/5 = 0.2$
fascinante	$0/5 = 0$	$1/5 = 0.2$

Ninguna palabra domina, porque dentro de cada documento todas las palabras aparecen solo una vez, haciendo que todas tengan el mismo TF.

Problema 4

Bigramas

- aprendo procesamiento
- procesamiento de
- de lenguaje
- lenguaje natural

Trigramas

- aprendo procesamiento de
- procesamiento de lenguaje
- lenguaje natural

Los n-gramas capturan mejor el significado cuando el orden de las palabras sí importa, eso pasa mucho en frases fijas, expresiones comunes, nombres compuestos, y detección de texto local.

Problema 5

"Este curso es increíble" → positivo

"No entendí nada" → negativo

"Es un curso" → neutral


La ambigüedad aparece cuando el texto:

- Tiene pocas palabras y poco contexto
- Usa ironía y sarcasmo, por ejemplo: "Qué curso tan increíble" con connotación negativa.
- Mezcla señales positivas y negativas como "El curso es bueno, pero muy difícil"
- Usa palabras generales que no expresan opinión como "Es un curso" donde hay un juicio claro.

Problema 6

En embeddings esa analogía funciona porque los vectores capturan relaciones, además de significado:

- La diferencia entre "rey" y "hombre" se parece a la diferencia entre "reina" y "mujer" así que al mover el vector "rey" en esa dirección se llega cerca de reina.
- Que las palabras estén cerca en el espacio vectorial significa que aparecen en contextos parecidos o cumplen roles semánticos relacionados. Es una medida de similitud.




Problema 7

1. Finanzas: fui al banco a abrir una cuenta
 2. Asiento (mueble): nos sentamos en el banco del parque
 3. Grupo: vimos un banco de peces cruzar la orilla
- Un modelo NLP suele resolver la ambigüedad usando el contexto alrededor de la palabra:
- En modelos clásicos se hacía con palabras vecinas (K-nn)
 - En modelos modernos los embeddings y modelos de contexto aprende que el "banco" cambia de significado.

Problema 8

- Quitando palabras no funcionales como: el, de, es, una, la, queda = análisis de datos parte importante inteligencia artificial!
2. Antes de quitar stopwords: - Suena natural y completa.
Después:
- Siguiendo entendible pero pierde fluidez y relaciones gramaticales.
 3. NO, depende de la tarea.
 - Si, en búsquedas simples
 - No cuando la gramática importa.

Problema 9.



1. Entrada: "Me encanta este producto"
2. Limpieza: Quitar comas, normalizar mayúsculas / minúsculas, quitar stopwords
3. Tokenización: separar palabras.
4. Vectorización: convertir palabras a números (vectores) con bow; TF-IDF o embeddings
5. Clasificación: predecir una etiqueta: positivo, negativo, neutro.

Pregunta 1.



$$I = \begin{bmatrix} 0 & 128 & 255 \\ 64 & 0 & 200 \\ 255 & 128 & 0 \end{bmatrix}$$

Escala de grises: Es una matriz de 2D (una sola capa de intensidad)

RGB: Es un tensor en 3D. En lugar de una matriz, tenemos 3 matrices (canales) superpuestos (rojo, verde, azul) Cada pixel se representa por un vector $[R, G, B]$.

Pregunta 2.

1. Descomposición en canales

Una imagen digital a color no es una sola matriz, sino la superposición de 3 capas independientes.

- Canal R (Red): Contiene la intensidad de rojo en cada pixel.

- Canal G (Green): Intensidad de verde.

- Canal B (Blue): Intensidad de azul.

Cada canal es, por sí solo una matriz en escala de grises donde el blanco representa el máximo de ese color y el negro la ausencia total. Al combinarse mediante síntesis aditiva crean el espectro completo de colores.

2. Si ponemos todos los valores de la matriz B en 0:

2.1 Dominancia de los tonos amarillos:

El cerebro percibirá una imagen compuesta solo de rojo y verde. En el modelo aditivo Rojo + Verde = Amarillo.

2.2 Pérdida de información: Cualquier objeto de fuera puramente azul (Como un cielo) se verá negro y los colores compuestos (como el morado o el blanco) perderían su componente azul, alterando totalmente la fidelidad de la imagen.

Problema 3.

3.1 La operación consiste en el producto punto entre la submatriz de la imagen y el Kernel.

① Submatriz (2x2 arriba izquierda): $\begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}$

② Operación: $(1 \times 1) + (2 \times 0) + (4 \times 10) + (5 \times -1)$

③ Resultado: $1 + 0 + 0 - 5 = -4$

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

3.2 Este filtro es un detector de bordes diagonales o cambios de intensidad en diagonal.

- Al tener valores opuestos (1 y -1) en la diagonal principal y ceros en la otra el filtro arroja un valor alto (positivo o negativo) solo cuando hay una diferencia marcada entre los pixels de esa diagonal.

- Si los pixels fueran iguales (todos 5) el resultado sería $5 - 5 = 0$ indicando una zona plana sin bordes.

Problema 4.

① El operador Sobel utiliza dos kernels (matrices pequeñas) de 3×3 uno para cambios horizontales (G_x) y otro para cambios verticales (G_y).

- Operador: El filtro recorre la imagen (convolución) calculando la diferencia de intensidad entre píxeles adyacentes.
- Gradiente: Si hay un cambio brusco de color (negro a blanco) el resultado numérico es alto lo que genera una línea brillante en la imagen resultante. Si la zona es uniforme, el resultado es cero (negro).

② Los bordes son fundamentales porque:

- 1- Reducción de datos: Eliminan información irrelevante (como texturas de fondo) y mantienen solo la estructura geométrica del objeto.
- 2- Extracción de características: son el primer paso para detectar formas (círculos y cuadrados) que luego permiten identificar objetos complejos (caras, autos, animales).
- 3- Invarianza: Los bordes suelen ser más estables ante cambios de iluminación que los colores sólidos.

Problema 5.


Según vemos en la imagen, podemos enlistar:

- 1- Flip (volteo): Espejar la imagen en diferentes ángulos.
- 2- Rotation (rotación): Girar la imagen en diferentes ángulos.
- 3- Blur (desenfoque): Simular pérdida de nitidez o movimiento.
- 4- Exposure/Contrast (exposición): Cambiar el brillo y contraste para simular distintas condiciones de luz.
- 5- GrayScales: Eliminar el color para que el modelo se enfoque en las formas.

② Diversidad forzada: Al presentarle al modelo la misma imagen con cambios, evitamos que memorice la posición exacta de los píxeles.

- Invarianza: Obligamos a la red neuronal a entender que gato sigue siendo un gato, aunque esté de cabeza, borroso o en la oscuridad.
- Generalización: En lugar de aprender un solo ejemplo, el modelo aprende la esencia del objeto que permite funcionar mejor con datos reales que nunca ha visto.

Problema 8



auto



persona

La calidad del dato es todo. Al etiquetar, surgen estos retos:

- Ambigüedad: de los límites:
¿La caja debe incluir la antena del auto o solo el cuerpo? ¿Y si la persona lleva una mochila?
- Oclusión: Si la persona está detrás del auto ¿dibujamos la caja solo de lo que se ve o estamos donde está todo su cuerpo?
- Objetos múltiples o amontonados: En una multitud, las cajas se enciman tanto que es difícil para el modelo separar una instancia de otra. (Non-Maximum Suppression).
- Subjetividad del etiquetador: Diferentes personas pueden dibujar cajas de distintos tamaños para el mismo objeto, introduciendo ruido en el entrenamiento.
- Truncamiento: Cuando el objeto está solo a la mitad, la caja no representa la forma real del objeto.

14 / mayo / 2026

Morino Navarrete Naomi Yalanci

Problema 9



- 1.1. Entrada (input): Una matriz (o cubo si es RGB) de pixeles.
- 1.2. Convolución: El "extractor de características". Filtramos que buscan bordes y texturas (sobel).
- 1.3. Pooling: El "reductor". Comprime la información y mantiene lo más importante (max pooling).
- 1.4. Fully Connected (capa densa): El "clasificador". Toma los rasgos extraídos y decide si la imagen es un coche o persona.
2. a) Explosión de parámetros: Una imagen de 1000×1000 pixeles tendría un millón de entradas. En una red densa la primera capa oculta tendría billones de conexiones, lo que computacionalmente imposible de entrenar.
- b) Pérdida de estructura espacial: Las redes densas "aplanan" la imagen a un vector, perdiendo la relación de vecindad entre pixeles.
- c) Falta de invarianza: Si un objeto se mueve unos pocos pixeles, una red densa lo vería como un patrón totalmente nuevo. La cnn, gracias a la convolución reconoce el patrón sin importar su ubicación exacta.

Ejercicio 11

Identificación de modalidades:

- Entrada: Imagen (Matriz) de píxeles y tensor)

- Salida: Texto (Secuencia de tokens / lenguaje natural)

¿Es unimodal o multimodal? - Es un sistema multimodal

- Acción: Procesa y relaciona información proveniente de dos tipos distintos que tienen estructuras y representaciones matemáticas diferentes (píxeles vs. texto). (palabras).

• Un ejemplo muy común es la búsqueda por voz en YouTube.

• Entrada: Audio (ondas sonoras).

• Salida: Video (Secuencia de imágenes y texto (títulos)).

Otro ejemplo: los sistemas de Traducción con lengua de señas:

• Entrada: Video

• Salida: Voz

Ejercicio 12

Concepto	Early Fusión (Fusión Temprana)	Late Fusión (Fusión Tardía)
	Se concatenan las características (features) crudas de bajo nivel de ambas modalidades antes de entrar al modelo de aprendizaje.	Se entrena un modelo independiente para cada modalidad y se combinan solo sus predicciones finales o capas de salida
Proceso	Imagen → Texto → Un solo vector de entrada → Red Neuronal.	(Imagen → Modelo A) + (Texto → Modelo B) → Promedio / Votación de resultados

12.2 Usamos early fusion cuando el texto y la imagen están íntimamente ligados (por ejemplo, una descripción técnica exacta de una pieza mecánica) la fusión temprana permite que la red detecte patrones cruzados, que se perderían si procesas cada etapa por separado. Ayuda a capturar la semántica compartida de forma mucho más profunda.

Ejercicio 15

CLIP (Contrastive Language - Image Pre-Training)

Funciona conectando conceptos visuales con lenguaje natural de forma masiva.

• Doble Codificación: Utiliza un decodificador de imagen y uno de texto que trabajan en paralelo.

• Alineación semántica: Durante su entrenamiento se le presentan millones de pares (imagen, texto) extraídos de internet.

• Espacio latente: Proyecta ambos tipos de datos a uno mismo espacio matemático para que la "foto de un gato" y la palabra "gato" tengan coordenadas similares.

15.2 El aprendizaje contrastivo es la clave de su eficiencia porque:

• Simplifica la tarea: En lugar de predecir cada palabra exacta de una descripción (que es muy difícil) el modelo solo debe distinguir qué texto corresponde o qué imagen entre un grupo de opciones.

2. Atracción y repulsión: El algoritmo optimiza la red para que los pares correctos se "atraigan" (distancia mínima) y los pares incorrectos se "repelan" (distancia máxima) en el espacio vectorial.
3. Zero-shot learning: Gracias a esto CLIP puede reconocer objetos que nunca vio en un entrenamiento específico, simplemente entendiendo la descripción textual.

Ejercicio 18.

- 18.1 Los modelos de IA no son racistas o sexistas por sí mismos, son espejos de los datos con los que se entrenan:
- Datos históricos: Si el data set (imágenes y texto de internet) contienen más fotos de hombres en roles de medicina y mujeres en enfermería, el modelo aprenderá esa correlación como una regla estadística.
 - Función de representatividad: Un desequilibrio en la cantidad de ejemplos para ciertos grupos refuerza estereotipos.
 - Anotación humana: Si las personas que etiquetaron los datos tenían prejuicios estos se transfieren al modelo.
- 18.2 Para construir una IA más justa podemos aplicar estas estrategias:
1. Curación de Datasets: Auditar y balancear los datos de entrenamiento para asegurar una representación equitativa de todos los géneros en todas las profesiones.
 2. Data argumentation ético: Generar artificialmente ejemplos que rompan el sesgo, crear más datos de enfermeros y doctoras mujeres.
 3. Debiasing (Desesgo) en embeddings: Aplicar técnicas matemáticas para limpiar el espacio vectorial, eliminando las correlaciones no deseadas entre género y profesión.
 4. Métricas de equidad: Evaluar el modelo no solo por su precisión general sino cómo se comporta entre diferentes grupos demográficos.

